Khuyến nghị công việc cho ứng viên

Võ Anh Quân (22521129), Võ Phi Thân (22521323), Võ Minh Quyền (22521227)
Nhóm 10 - DS300.Q11
GVHD: ThS. Huỳnh Văn Tín
Khoa Khoa học và Kỹ thuật Thông tin
Trường Đại học Công nghệ Thông tin - Đại học Quốc gia TP.HCM

Tóm tắt nội dung

Đề tài là khuyến nghị công việc dự trên các mô hình $bg3m3$, $paraphrase\ multilingualmpnet$, $labse$, $tfidf$, $w2v$ để khuyến nghị công việc dựa theo data từ topCV để huấn luyện và đầu vào là các từ khóa hoặc 1 bản CV của bản thân

1 Giới thiệu

1.1 Bối cảnh

Sự bùng nổ của thị trường tuyển dụng trực tuyến tại Việt Nam (TopCV, Vieclamnet...) đang dẫn đến tình trạng "quá tải thông tin", bộc lộ hạn chế của các công cụ tìm kiếm truyền thống:

- Về phía ứng viên: Việc tìm kiếm dựa trên từ khóa (keyword) thường bỏ sót các cơ hội tốt do cơ chế so khớp cứng nhắc, không nắm bắt được ý định tìm kiếm thực sự (ví dụ: tìm "Lập trình viên"không ra "Software Engineer").

- Về phía dữ liệu: Các bản mô tả công việc (JD) là văn bản phi cấu trúc, đa dạng về văn phong và ngôn ngữ, gây khó khăn cho các bộ lọc từ khóa đơn giản.

Do đó, nhu cầu xây dựng một hệ thống gợi ý (Recommendation System) thông minh, có khả năng hiểu ngữ nghĩa văn bản (Semantic Understanding) để tự động khớp nối nhu cầu tìm kiếm của người dùng (Query) với nội dung JD là vô cùng cấp thiết. Xuất phát từ thực tế đó, nhóm đã tiến hành đề tài khuyến nghị công việc nhằm giúp ứng viên dễ dàng tiếp cận được các vị trí phù hợp nhất với độ chính xác cao hơn, vượt qua rào cản của việc tìm kiếm từ khóa thông thường.

1.2 Nội dung đạt được

Đồ án tập trung xây dựng và đánh giá hiệu quả của hệ thống khuyến nghị công việc với các kết quả cụ thể sau:

1. Xây dựng bộ dữ liệu và Tiền xử lý Thu thập (Crawl) và làm sạch dữ liệu tuyển dụng thực tế từ TopCV. Thực hiện các bước tiền xử lý ngôn ngữ tự nhiên (NLP) cho tiếng Việt (loại bỏ stopword, chuẩn hóa thuật ngữ).

Ứng dụng và So sánh các mô hình Vector hóa Triển khai và so sánh hiệu năng của các phương pháp trích xuất đặc trưng (Feature Extraction) từ cơ bản đến nâng cao:

- Nhóm thống kê: Sử dụng $TF - IDF$ và $Word2Vec$ để làm cơ sở (baseline).
- Nhóm Transformer: $LaBSE$ (Language-agnostic BERT Sentence Embedding): Tối ưu cho việc khớp nối văn bản đa ngôn ngữ (Việt - Anh).$paraphrase - multilingual - mpnet - base - v2$: Mô hình mạnh mẽ trong việc nhận diện các câu có cấu trúc khác nhau nhưng cùng ý nghĩa.$BG3M3$: Mô hình mới (State-of-the-art) với khả năng xử lý đa ngôn ngữ và độ dài văn bản lớn tốt hơn.

1. Xây dựng cơ chế khuyến nghị (Recommendation Engine)Xây dựng luồng xử lý (Pipeline):Input: Nhận đầu vào là danh sách từ khóa (Keywords) hoặc tải lên file PDF CV.Embedding: Chuyển đổi Input và Database JD sang không gian vector.Matching: Tính toán độ tương đồng bằng $CosineSimilarity$.Ranking: Xếp hạng và trả về Top N công việc phù hợp nhất.

2 Các phương pháp hiện tại và Vấn đề tồn đọng

2.1 Phương pháp dựa trên từ khóa (Keyword-based)

Đây là phương pháp truyền thống nhất, thường sử dụng các kỹ thuật như so khớp chính xác (Exact matching) hoặc tính toán trọng số TF-IDF để đo lường độ tương đồng giữa CV và JD.

Vấn đề và Hạn chế:

- **Tìm các từ quá máy móc:** Hệ thống chỉ tìm kiếm các từ khóa trùng khớp chính xác. Ví dụ: Nếu JD yêu cầu "kỹ năng giao tiếp"nhưng CV ghi "khả năng đàm phán", hệ thống sẽ bỏ qua dù ngữ nghĩa tương đồng.
- **Mất ngữ cảnh:** Các mô hình như TF-IDF coi các từ là độc lập (Bag-of-Words), không nắm bắt được thứ tự từ và ngữ cảnh câu. Ví dụ: "Công ty bảo vệ"và "Bảo vệ công ty"sẽ có vector giống hệt nhau.
- **Vấn đề Cold Start**: Khi mới vào người dùng và cả ứng dụng đều chưa có thông tin cụ thể, vì vậy chỉ có thể khuyến nghị những công việc phổ biến nhất so với tất cả.

2.2 Phương pháp Lọc cộng tác (Collaborative Filtering - CF)

Phương pháp này dựa trên lịch sử tương tác của người dùng (user-item interaction), ví dụ: lịch sử ứng tuyển,

lượt xem, hoặc đánh giá công việc. Hệ thống sẽ gợi ý các công việc mà những ứng viên tương tự đã quan tâm.

Vấn đề và Hạn chế:

- **Khó khăn trong dữ liệu:** Đây là hạn chế lớn nhất. Khi triển khai mô hình thì yêu cầu phải có lịch sử tương tác và đánh giá nhưng rất ít khi người dùng đánh giá 1 công ty trên các trang Web như TopCV hay các công ty cũng không công bố người dùng nào được tuyển để có cơ sở đánh giá
- **Thiên kiến phổ biến (Popularity Bias):** Các công việc "hot"được gợi ý quá nhiều, trong khi các công việc phù hợp ít người nộp đơn lại bị bỏ qua.

2.3 Phương pháp Nhúng từ tĩnh (Static Word Embeddings)

Sự ra đời của Word2Vec, GloVe, ... đã cải thiện khả năng biểu diễn ngữ nghĩa so với TF-IDF bằng cách chuyển từ vựng sang không gian vector.

Vấn đề và Hạn chế:

- **Không xử lý tốt từ chưa biết:** Với đặc thù thị trường Việt Nam, các thuật ngữ lóng hoặc từ viết tắt mới (như "Dev", "QC", "AI Engineer") xuất hiện liên tục, các mô hình tĩnh khó cập nhật kịp thời.

2.4 Thách thức đặc thù của dữ liệu tuyển dụng tại Việt Nam

Ngoài các hạn chế kỹ thuật trên, dữ liệu từ các nền tảng như TopCV đặt ra những thách thức riêng mà các phương pháp cũ không giải quyết được:

- **Đa ngôn ngữ hỗn hợp (Code-switching):** Các JD thường viết trộn lẫn tiếng Anh và tiếng Việt (VD: "Yêu cầu kinh nghiệm *deploy* hệ thống trên *AWS*"). Các mô hình đơn ngữ (chỉ huấn luyện trên tiếng Anh hoặc tiếng Việt) sẽ thất bại trong việc hiểu trọn vẹn ngữ nghĩa.
- **Độ dài văn bản (Long Document):** Một bản CV hoặc JD chi tiết thường rất dài, vượt quá giới hạn token của các mô hình BERT tiêu chuẩn (thường chỉ 512 tokens), dẫn đến việc mất mát thông tin quan trọng nằm ở cuối văn bản.

Kết luận: Để giải quyết các vấn đề về ngữ nghĩa, đa ngôn ngữ và độ dài văn bản nêu trên, đề tài này đề xuất sử dụng các mô hình Transformer tiên tiến (BG3M3, LaBSE, Multilingual MPNet) để tối ưu hóa hiệu quả gợi ý hoặc các phương pháp lai để có đánh giá khách quan hơn.

3 Xây dựng bộ dữ liệu

Bộ dữ liệu được cào từ TopCV sử dụng Airflow.

3.1 Thu thập dữ liệu

Dữ liệu được thu thập với các cột là:

- job url: Địa chỉ URL công việc
- title: Tiêu đề công việc
- salary range: Khoảng lương
- location: Địa chỉ công ty
- description: Mô tả công việc
- requirements: Yêu cầu công việc
- benefit: Quyền lợi
- company information: gồm tên, url, thông tin, địa chỉ
- position: Vị trí công việc
- experience: Yêu cầu kinh nghiệm
- quantity: Số lượng cần tuyển
- branch: Lĩnh vực công việc
- short requirements: yêu cầu cơ bản
- short benefits: quyền lợi cơ bản
- specializations: năng lực cơ bản

3.2 Phân bố dữ liệu

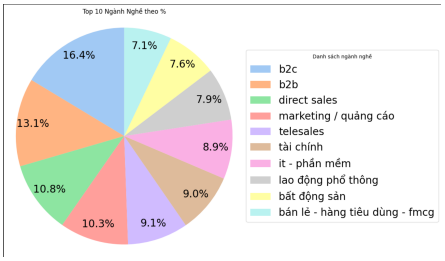

Hình 1: Tỉ lệ của top 10 ngành nghề

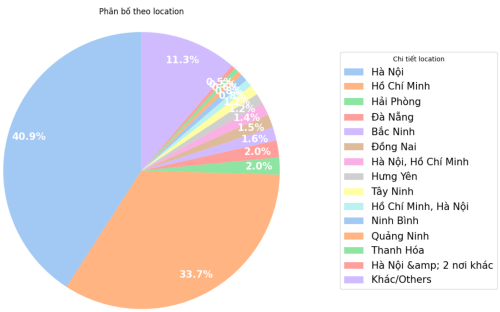

Hình 2: Phân bố theo tỉnh

Từ hình 1 và hình 2 ta thấy rằng dữ liệu được phân bố khá đều và cao nhất thuộc về các nhóm ngành kinh doanh và tài chính, trong đó tập trung chủ yếu ở Hà Nội và TP Hồ Chí Minh

3.3 Tiền xử lý và xử lý dữ liệu

Nhóm đã tiến hành xử lý các Stopword tiếng việt và tiến hành tách các trường như Salary hay Location để có các tiêu chí đánh giá phù hợp. Ví dụ như Salary trrong TopcV sẽ có nhiều khoảng ví dụ như trên 2 triệu, 2 triệu đến 5 triệu, thỏa thuận, hay khác ở đơn vị như có công ty trả bằng USD có nơi lại trả bằng VND gây khó khăn trong đánh giá nên đã tiến hành tách ra thành 3 trường là Min Salary, Max Salary và Currency Salary để thuận tiện trong mô hình khuyến nghị.

4 Mô Hình

Đề tài chú trọng phương pháp content-based. Do đó, nhóm lựa chọn nhiều phương pháp, nhằm đưa ra được khuyến nghị hiệu quả nhất dựa vào các cột dữ liệu đặc trưng của bộ dữ liệu như: title, desciption, requirements, benefit.

4.1 TF-IDF

TF-IDF (Term Frequency – Inverse Document Frequency) là một kỹ thuật biểu diễn nội dung rất phổ biến, đặc biệt trong hệ khuyến nghị dựa trên nội dung (Content-Based Filtering).Cụ thể, được tính bằng tích của hai chỉ số: TF và IDF.

- TF (Term Frequency) dùng để đo lường tần suất một từ xuất hiện trong một văn bản cụ thể. Công thức:

  $$\mathrm{tf}(t,d) = \frac{f(t,d)}{\max\{f(w,d) : w \in d\}}$$

  Trong đó:

  - $\mathrm{tf}(t,d)$ là tần suất xuất hiện của từ t trong văn bản d, có giá trị trong khoảng $[0,1]$.
  - $f(t,d)$ là số lần xuất hiện của từ t trong văn bản d.
  - $\max\{f(w,d) : w \in d\}$ là số lần xuất hiện nhiều nhất của một từ bất kỳ trong văn bản d.

- IDF (Inverse Document Frequency)dùng để đo lường mức độ "hiếm"của từ trong toàn bộ tập dữ liệu, giảm trọng số của những từ phổ biến này và tăng trọng số cho những từ hiếm. Công thức:

  $$\mathrm{idf}(t,D) = \log \frac{|D|}{|\{d \in D : t \in d\}|}$$

  Trong đó:

  - $|D|$ là tổng số văn bản trong tập D.
  - $|\{d \in D : t \in d\}|$ là số văn bản trong tập D có chứa từ t, với điều kiện $\mathrm{tf}(t,d) \neq 0$.

  Nếu từ t không xuất hiện trong bất kỳ văn bản nào trong tập D thì mẫu số bằng 0, dẫn đến phép chia không hợp lệ. Vì vậy, trong thực tế người ta thường sử dụng công thức điều chỉnh như sau:

  $$\mathrm{idf}(t,D) = \log \frac{|D|}{1 + |\{d \in D : t \in d\}|}$$

Công thức tổng quát:

$$\mathrm{tfidf}(t,d,D) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

Những từ có giá trị TF-IDF cao là những từ xuất hiện nhiều trong mô tả công việc, và xuất hiện ít trong các mô tả khác. Việc này giúp lọc ra những từ phổ biến và giữ lại những từ có giá trị cao (từ khoá). Sau khi vector hóa, nếu nội dung được nhập vào hoặc CV của người dùng có cùng các từ khóa quan trọng với mô tả công việc, thì giá trị TF-IDF sẽ cao và được hệ thống khuyến nghị. Tuy nhiên, kỹ thuật TF-IDF chỉ sử dụng dựa vào sự xuất hiện của từ ngữ, không thể hiểu được ngữ nghĩa sâu. Điều này sẽ gây ra nhiều thiếu sót, vì tiếng Việt chứa rất nhiều từ đồng nghĩa, đồng âm.

4.2 Các mô hình embedding đa ngôn ngữ: BGE-M3, paraphrase-multilingual-mpnet-base-v2, LaBSE

Mô hình embedding đa ngôn ngữ là một mạng nơ-tron (neural network) (thường dựa trên kiến thức Transformer) được huấn luyện để chuyển đổi văn bản (từ, câu, hoặc đoạn văn) từ nhiều ngôn ngữ khác nhau thành các vector số học (embeddings) trong cùng một không gian vector chung. Hiểu đơn giản, dựa vào các mô hình embedding đa ngôn ngữ, các nội dung có ý nghĩa tương đồng (semantic similarity) sẽ nằm gần nhau trong không gian vector, bất kể chúng được viết bằng ngôn ngữ nào. Mô hình embedding đa ngôn ngữ giải quyết được các vấn đề như: học chuyển tiếp (zero-shot cross-lingual transfer), tìm kiếm đa ngôn ngữ (cross-lingual retrieval) và đơn giản hóa hệ thống (chỉ một mô hình đa ngôn ngữ, thay vì nhiều mô hình ngôn ngữ riêng biệt). Tóm lại, điều này giúp giải quyết được sự phức tạp về ngữ nghĩa của tiếng Việt. Đồng thời, các mô tả công việc chứa nhiều từ tiếng Anh xuất hiện (như trainer, telesale, marketing, designer, fresher, senior, junior,...) có thể được giải quyết bởi các mô hình này. Cụ thể, nhóm đã áp dụng các mô hình embedding đa ngôn ngữ sau:

- BGE-M3: là một mô hình embedding văn bản tiên tiến do Beijing Academy of Artificial Intelligence (BAAI) phát triển. Mô hình hỗ trợ nhiều phương pháp truy vấn, cho phép mô hình linh hoạt và mạnh mẽ trong nhiều ứng dụng RAG, tìm kiếm tài liệu và QA. Mô hình còn có thể xử lý hơn 100 ngôn ngữ khác nhau và các văn bản dài lên tới 8192 tokens (khoảng hàng nghìn từ). Điều này giúp xử lý các tài liệu dài và nhiều ngôn ngữ một cách hiệu quả. Cụ thể, các mô tả công việc có thể được mô hình BGE-M3 xử lý một cách hiệu quả.

- paraphrase-multilingual-mpnet-base-v2: là một mô hình embedding đa ngôn ngữ thuộc thư viện Sentence Transformers, được huấn luyện để chuyển đổi câu và văn bản thành vector số (embeddings) có ý nghĩa ngữ nghĩa. Mô hình dựa trên kiến trúc MPNet và tối ưu cho các tác vụ so snahs độ tương

đồng ngữ nghĩa và đoạt nghĩa (paraphrase) trên nhiều ngôn ngữ khác nhau. Cụ thể, mô hình hỗ trợ hơn 50 ngôn ngữ khác nhau và xử lý tốt với các văn bản trong khoảng 128 token, nếu dài hơn sẽ bị cắt ngắn bớt (trucation), đầu ra embedding dày 768 chiều. Do đó, mô hình được ứng dụng vào sematic search, paraphrase detection, cross-lingual retrieval, clustering và classification. Đối với bài toán, mô hình paraphrase-multilingual-mpnet-base-v2 giải quyết được khá nhiều vấn đề xuất hiện trong các mô tả công việc, tương tự như BGE-M3, nhưng khá hạn chế về số lượng từ trong mỗi dòng dữ liệu đầu vào.

- LaBSE: (Language-agnostic BERT Sentence Embedding) là mô hình do Google Research đề xuất. Mô hình được sử dụng là phiên bản Sentence Transformers. Mô hình dùng chuyển văn bản thành embedding sao cho các câu có cùng ý nghĩa, kể cả khác ngôn ngữ, có vector gần nhau trong không gian ngữ nghĩa. Điểm mạnh của LaBSE là cross-lingual semantic similarity và clustering đa ngôn ngữ. Ngoài ra, mô hình này còn hỗ trợ 109 ngôn ngữ, và mã hóa mỗi câu thành vector dày 768 chiều. Giới hạn đầu vào của mô hình từ 128 đến 256 tokens. Mô hình LaBSE giải quyết được vấn đề ngữ nghĩa của các mô tả tiếng Việt, cũng như nhận biết được sự tương đồng của các câu khác ngôn ngữ. Tuy nhiên, LaBSE không phù hợp nếu các mô tả quá dài.

4.3 Word2Vec - Doc2Vec

Word2Vec là một mô hình embedding từ (word embedding) kinh điển do Google (Tomas Mikolov et al.) đề xuất năm 2013. Mô hình biểu diễn mỗi từ thành một số liên tục, sao cho các từ có ngữ nghĩa hoặc ngữ cảnh giống nhau sẽ có vector gần nhau trong không gian embedding, khác với các mô hình embedding đa ngôn ngữ ở phần trên xử lý ở cấp độ câu. Word2Vec là một mô hình nông (shallow neural network), gồm 2 kiến trúc chính: CBOW (Continuos Bag of Words) và Skip-gram. Với CBOW, mô hình sẽ dự đoán từ trung tâm dựa vào các từ xung quanh. Ngược lại, với Skip-gram, mô hình sẽ dự đoán các từ xung quanh từ một từ trung tâm. Mô hình Word2Vec rất nhẹ và nhanh nhưng khá nhiều hạn chế như không hiểu ngữ cảnh, không embedding cho câu và kém xa với các mô hình hiện đại về sematic similarity.
Kế thừa từ Word2Vec, Doc2Vec (còn gọi là Paragraph Vector) là một mô hình embedding tài liệu do Lê Quốc Vinh và Tomas Mikolov đề xuất năm 2014. Doc2Vec có khả năng biểu diễn câu, đoạn hoặc tài liệu thành một vector số cố định, sao cho các tài liệu có nội dung hoặc ngữ nghĩa tương tự sẽ có vector gần nhau. Hiểu đơn giản, thay vì biểu diễn từ thành những vector, phương pháp Doc2Vec sẽ biểu diễn văn bản thành những vector tương ứng. Khác với cấp độ từ, cấp độ văn bản không có những cấu trúc logic như từ ngữ. Doc2Vec cũng có 2 biến thể tương tự như Word2Vec: đó là PV-DM (Distributed Memory) và PV-DBOW (Distributed Bag of Words). Mặc dù, Doc2Vec có những khác biệt với Word2Vec, nhưng ưu và nhược điểm khá tương đồng với Word2Vec.

4.4 Phương pháp lai

Đối với các hệ thống gợi ý, phương pháp lai giúp kết hợp hai hay nhiều kỹ thuật khuyến nghị, từ đó cho ra danh sách khuyến nghị phù hợp nhất. Cụ thể, phương pháp lai có thể bù đắp ưu và nhược điểm của các mô hình cho nhau, hoặc có thể dùng để giải quyết những vấn đề cố hữu thường xuất hiện trong một hệ khuyến nghị như "khởi động lạnh (cold start) và dữ liệu thưa (data sparsity). Trong đề tài này, nhóm ứng dụng hai phương pháp là Weighted và Switching.

- Đối với phương pháp Weighted, đây là phương pháp mà hệ thống sẽ chạy song song nhiều thuật toán gợi ý khác nhau. Mỗi thuật toán sẽ trả về một điểm số cho các công việc. Điểm số cuối cùng của sản phẩm sẽ là tổng trọng số (weighted sum) của các điểm số thành phần. Phương pháp khá đơn giản và dễ sử dụng nhưng có thể tối ưu đáng kể kết quả từ các mô hình.

- Đối với phương pháp Switching, phương pháp này chọn một trong các thuật toán để sử dụng tại một thời điểm cụ thể, dựa trên một tiêu chí hoặc "luật"(heuristic) nhất định. Hệ thống sẽ "chuyển mạch"(switch) giữa các thuật toán tùy vào tình huống. Phương pháp giúp hệ thống trở nên linh động và thích ứng được với từng đầu vào, yêu cầu của người dùng.

5 Thực nghiệm

5.1 Thiết lập thực nghiệm

Với nhiều lựa chọn từ các mô hình, việc kết hợp các mô hình có hiệu quả giúp đem lại kết quả tối ưu nhất, bù đắp được những khuyết điểm của mỗi mô hình. Sau quá trình thử nghiệm, mô hình dựa vào phương pháp lai Weighted mà nhóm đề xuất là SemLex, kết hợp giữa TF-IDF và mô hình embedding đa ngôn ngữ BGE-M3. Với TF-IDF, đây là một kỹ thuật khuyến nghị cơ bản dựa vào sự xuất hiện của từ ngữ. Mặt khác, mô hình BGE-M3 hỗ trợ quá trình xử lý ngôn nhiều loại ngôn ngữ và hiểu được ngữ nghĩa của văn bản. Cuối cùng, tham số các mô hình cũng rất quan trọng. Các mô tả công việc trong bộ dữ liệu là của các công ty tại Việt Nam. Tuy nhiên, các mô tả này thường xuyên chứa các từ chuyên ngành tiếng Anh hoặc toàn bộ mô tả là tiếng Anh. Do đó, việc hiểu được ngữ nghĩa có thể dẫn đến kết quả khuyến nghị phù hợp nhất. Tham số giữa hai kết quả khuyến nghị TF-IDF và BGE-M3 là 0,3 và 0,7. Đây là mô hình chính được sử dụng mặc định, nhóm chúng tôi vẫn triển khai các mô hình khác được nhắc tới ở chương 4 nhằm so sánh và phân tích kết quả

$$Score = 0.3 \times S_{TF-IDF} + 0.7 \times S_{BGE-M3}$$

Để đánh giá hiệu quả của hệ thống khuyến nghị, nhóm thiết lập kịch bản thực nghiệm tập trung vào khả năng truy xuất thông tin của các mô hình dựa trên mức độ tương đồng ngữ nghĩa. Quy trình thực nghiệm được chuẩn hóa như sau. Dữ liệu sử dụng cho thực nghiệm là bộ dữ liệu tuyển dụng đã được thu thập và làm sạch từ TopCV. Mỗi mẫu dữ liệu công việc bao gồm các trường thông tin đặc trưng: tiêu đề (title), mô tả (description), yêu cầu (requirements) và quyền lợi (benefit). Đầu vào của hệ thống được định nghĩa là một tập hợp các từ khóa. Query đầu vào sẽ được vector hóa thông qua các mô hình ngôn ngữ đã đề xuất để chuyển đổi sang không gian vector V_{query}. Để kiểm chứng giả thuyết về tầm quan trọng của ngữ cảnh trong khuyến nghị, chúng tôi tiến hành thực nghiệm theo hai chiến lược tìm kiếm riêng biệt:

1. Tìm kiếm dựa trên Tiêu đề: Trong kịch bản này, không gian tìm kiếm chỉ giới hạn ở trường title của tin tuyển dụng. Hệ thống tính toán độ tương đồng Cosine giữa vector của truy vấn đầu vào V_{query} và vector của tiêu đề công việc V_{title}. Mục tiêu là để ánh giá khả năng khớp lệnh nhanh khi người dùng chỉ quan tâm đến tên vị trí công việc cụ thể (ví dụ: "Java Developer", "Marketing Manager").

2. Tìm kiếm dựa trên Nội dung tổng hợp: Trong kịch bản này, nhóm thực hiện ghép nối tất cả các trường thông tin văn bản quan trọng của một bản ghi JD thành một đoạn văn bản thống nhất. Đoạn văn bản tổng hợp này sau đó được vector hóa thành $V_{overall}$. Hệ thống sẽ tính toán độ tương đồng Cosine giữa V_{query} và $V_{overall}$. Mục tiêu để đánh giá khả năng hiểu sâu ngữ nghĩa, giúp tìm kiếm các công việc có tiêu đề không trùng khớp từ khóa nhưng có nội dung mô tả phù hợp với kỹ năng của ứng viên.

Với cả hai chiến lược, sau khi tính toán độ tương đồng. Hệ thống sẽ thực hiện xếp hạng và trả về danh sách Top N công việc có điểm số tương đồng cao nhất.

5.2 Thiết kế Tập dữ liệu Kiểm thử (Test Set Construction)

Do hệ thống chưa có dữ liệu log hành vi người dùng thực tế, nhóm nghiên cứu đã xây dựng một tập dữ liệu kiểm thử tiêu chuẩn (Benchmark Dataset) gồm 20 truy vấn đại diện, được thiết kế theo phương pháp Lấy mẫu phân tầng theo kịch bản (Stratified Scenario-based Sampling).Quy trình xây dựng và gán nhãn được thực hiện như sau:

1. **Cấu trúc tập truy vấn đa dạng (Query Diversity):** Tập dữ liệu bao phủ 5 nhóm ngành nghề chiếm thị phần lớn nhất trên thị trường tuyển dụng hiện nay (CNTT, Kinh doanh, Marketing, Hành chính, và Các ngành đặc thù). Mỗi truy vấn q được cấu trúc gồm hai thành phần:
   - *Truy vấn ngôn ngữ tự nhiên (q_{text}):* Mô phỏng cách người dùng nhập liệu thực tế (VD: "Lập trình viên Frontend ReactJS lương cao tại Hà Nội").
   - *Tập ràng buộc cốt lõi (K_{core} - must_have):* Danh sách các từ khóa bắt buộc phải xuất hiện để đảm bảo tính phù hợp (VD: $\{\text{Frontend}, \text{ReactJS}, \text{Hà Nội}\}$).

   Các truy vấn được thiết kế để kiểm thử khả năng xử lý đa dạng của mô hình, bao gồm: *Kỹ năng chuyên môn* (Python, SQL), *Vị trí địa lý* (Hà Nội, Hồ Chí Minh), và *Hình thức làm việc* (Remote, Part-time).

2. **Cơ chế gán nhãn Heuristic (Heuristic Labeling Strategy):** Để xây dựng tập Ground Truth (kết quả đúng) một cách khách quan, nhóm áp dụng luật gán nhãn dựa trên độ trùng khớp từ khóa (Keyword Intersection). Một công việc d được coi là phù hợp (*Relevant*) với truy vấn q nếu thỏa mãn điều kiện:

$$|K_{core} \cap W_d| \geq \theta$$

   Trong đó:
   - W_d: Tập các từ vựng xuất hiện trong bản mô tả công việc d.
   - K_{core}: Tập từ khóa "must_have"được định nghĩa trong cấu trúc truy vấn.
   - θ: Ngưỡng quyết định (Decision Threshold).

3. **Thiết lập tham số thực nghiệm:** Dựa trên cấu trúc dữ liệu, nhóm thiết lập $\theta = 2$ (tương ứng với biến min_match trong thuật toán).
   - *Lý do chọn ngưỡng 2:* Các truy vấn thường chứa 3 thành tố (Ví dụ: Vai trò + Kỹ năng + Địa điểm). Việc yêu cầu khớp tuyệt đối (3/3) thường dẫn đến bỏ sót các kết quả tiềm năng do sự khác biệt trong cách diễn đạt (ví dụ: JD không ghi rõ địa điểm trong tiêu đề nhưng có trong nội dung). Ngưỡng tối thiểu 2 từ khóa giúp cân bằng giữa độ chính xác (Precision) và độ phủ (Recall), đảm bảo các kết quả được gán nhãn là thực sự liên quan về mặt ngữ nghĩa chính.

5.3 Các thang đánh giá

5.3.1 Các độ đo đánh giá dựa trên mức độ liên quan

1. Precision@K: Đây là thước đo cơ bản nhất để đánh giá tỷ lệ các công việc phù hợp xuất hiện trong K kết quả đầu tiên. Chỉ số này cho biết khả năng lọc nhiễu của mô hình, tuy nhiên nó không đánh giá được thứ tự xuất hiện của các kết quả trong danh sách.

$$P@K = \frac{\text{Số lượng kết quả phù hợp trong Top K}}{K}$$

2. HR@K: Chỉ số đo lường tỷ lệ các truy vấn có xuất hiện ít nhất một kết quả phù hợp trong danh sách Top K gợi ý. Trong bài toán tuyển dụng, HR@K trả lời câu hỏi: "Hệ thống có gợi ý được bất kỳ công việc nào đúng ý ứng viên trong 10 kết quả

đầu không?". Nếu HR@10 thấp, nghĩa là hệ thống hoàn toàn thất bại trong việc tìm kiếm.

$$HR@K = \frac{\text{Số lượng truy vấn có ít nhất 1 kết quả đúng top K}}{\text{Tổng số truy vấn}}$$

5.3.2 Các chỉ số đánh giá xếp hạng

Do tính chất của hệ khuyến nghị là ưu tiên đưa các kết quả tốt nhất lên đầu danh sách để tối ưu trải nghiệm người dùng, nhóm tập trung vào 3 chỉ số trọng yếu sau:

1. Mean Reciprocal Rank (MRR): Đánh giá khả năng đưa kết quả đúng đầu tiên lên vị trí cao nhất. MRR là trung bình nghịch đảo thứ hạng $rank_i$ của kết quả phù hợp đầu tiên tìm thấy. MRR càng cao chứng tỏ người dùng càng ít phải cuộn xuống để thấy công việc mong muốn

$$MRR = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{rank_i}$$

2. Mean Average Precision (MAP): Nếu như MRR chỉ quan tâm đến kết quả đúng đầu tiên, thì MAP là thước đo toàn diện hơn, đánh giá chất lượng xếp hạng của toàn bộ danh sách các công việc được gợi ý. Để tính MAP, trước hết ta cần tính độ chính xác trung bình (Average Precision - AP) cho từng truy vấn q riêng lẻ.

$$AP(q) = \frac{1}{m}\sum_{k=1}^{N}(P@k \times rel(k))$$

Trong đó:

- m: Tổng số công việc phù hợp thực tế có trong cơ sở dữ liệu (ground truth) cho truy vấn đó.
- $P@k$: Độ chính xác tại vị trí k.
- $rel(k)$: Hàm chỉ thị (indicator function), bằng 1 nếu kết quả tại vị trí k phù hợp, ngược lại bằng 0.

MAP là trung bình cộng của AP trên toàn bộ tập hợp các truy vấn $|Q|$:

$$MAP = \frac{1}{|Q|}\sum_{q\in Q}AP(q)$$

MAP đo lường sự "ổn định"của thuật toán. Một mô hình có MAP cao nghĩa là nó không chỉ tìm thấy các công việc phù hợp, mà còn gom cụm chúng lên các vị trí đầu tiên của danh sách. Trong bài toán tuyển dụng, điều này đảm bảo rằng ứng viên nhìn thấy nhiều cơ hội phù hợp nhất có thể ngay trong những lượt lướt đầu tiên, thay vì phải tìm kiếm các kết quả đúng nằm rải rác xen kẽ với các kết quả sai.

3. Normalized Discounted Cumulative Gain ($NDCG$): Đây là chỉ số quan trọng nhất, đánh giá chất lượng xếp hạng dựa trên nguyên tắc: kết quả phù hợp xuất hiện ở vị trí càng cao thì càng có giá trị ,và giá trị này sẽ giảm dần nếu xuất hiện ở vị trí thấp. $NDCG$ phạt nặng hệ thống nếu nó đẩy các công việc phù hợp nhất xuống dưới đáy danh sách, đảm bảo các "Hot Job"hoặc công việc khớp nhất luôn hiển thị trong tầm mắt ứng viên

$$NDCG_p = \frac{DCG_p}{IDCG_p}; DCG_p = \sum_{i=1}^{p}\frac{rel_i}{\log_2(i+1)}$$

Trong đó:

- rel_i: Mức độ phù hợp của kết quả tại vị trí i.
- $IDCG_p$: Giá trị DCG_p của danh sách xếp hạng lý tưởng (khi tất cả các kết quả phù hợp nhất đều được xếp lên đầu).

6 Phân tích kết quả

6.1 Kết quả đánh giá

Mô hình đề xuất SemLex (kết hợp TF-IDF và BGE/LaBSE trên dữ liệu đầy đủ) đạt kết quả cao nhất trên hầu hết các chỉ số quan trọng (NDCG@10 = 0.8, MAP = 0.105).

Nhóm mô hình Embedding (Word2Vec, Doc2Vec) cho kết quả thấp nhất, chứng tỏ việc học vectơ từ ngữ đơn lẻ không hiệu quả bằng các mô hình ngôn ngữ lớn (Transformer) hoặc khớp từ khóa trực tiếp (TF-IDF) đối với dữ liệu tuyển dụng đặc thù.

Bảng 1: Kết quả đánh giá top 5

Model	Type	H@5	P@5	NDCG@5	MAP@5	MRR@5
BGE-M3	title	1	0.72	0.75	0.032	0.917
	overall	0.95	0.73	0.76	0.037	0.885
Doc2Vec	title	0.75	0.36	0.36	0.009	0.529
	overall	0.2	0.08	0.087	0.0008	0.142
Doc2Vec-dbow	title	0.75	0.48	0.51	0.01	0.7
	overall	0.95	0.55	0.563	0.021	0.717
SemLex	title	1	0.79	0.8	0.037	0.9
	overall	0.9	0.74	0.781	0.04	0.9
LaBSE	title	1	0.68	0.7	0.035	0.835
	overall	1	0.77	0.763	0.032	0.827
MPNET	title	0.8	0.42	0.427	0.017	0.572
	overall	0.8	0.47	0.447	0.02	0.5
TFIDF	title	1	0.78	0.787	0.034	0.883
	overall	0.9	0.2	0.722	0.034	0.78
Word2Vec	title	0.1	0.05	0.042	0.0002	0.05
	overall	0.3	0.13	0.132	0.001	0.195
Word2Vec-sg	title	0.75	0.41	0.418	0.008	0.551
	overall	0.15	0.03	0.031	0.004	0.0725

Ngoài ra nhóm còn tiến hành đánh giá thủ công với top 10 kết quả trả về từ tập query trên, tổng cộng là 3600 dòng, xem **Bảng 4**

6.2 So Sánh

1. **Hiệu năng của mô hình Thống kê (TF-IDF):** Trong không gian tìm kiếm giới hạn ở tiêu đề (Title), TF-IDF đạt kết quả khả quan (NDCG@10 $\approx$ 0.737) nhờ cơ chế khớp từ khóa chính xác

Bảng 3: Kết quả đánh giá top 20

Model	Type	H@20	P@20	NDCG@20	MAP@20	MRR@20
BGE-M3	title	1	0.545	0.6	0.072	0.917
	overall	1	0.62	0.66	0.087	0.89
Doc2Vec	title	0.9	0.285	0.3	0.016	0.541
	overall	0.3	0.1125	0.107	0.0024	0.153
Doc2Vec-dbow	title	0.85	0.42	0.445	0.022	0.709
	overall	1	0.497	0.515	0.042	0.722
SemLex	title	1	0.6	0.652	0.082	0.9
	overall	1	0.672	0.712	0.105	0.912
LaBSE	title	1	0.57	0.605	0.079	0.835
	overall	1	0.666	0.872	0.084	0.827
MPNET	title	1	0.43	0.433	0.048	0.594
	overall	1	0.467	0.464	0.057	0.522
TFIDF	title	1	0.602	0.654	0.075	0.883
	overall	1	0.685	0.697	0.094	0.796
Word2Vec	title	0.3	0.055	0.05	0.00049	0.07
	overall	0.35	0.095	0.104	0.0024	0.202
Word2Vec-sg	title	0.95	0.385	0.394	0.019	0.576
	overall	0.4	0.05	0.046	0.0001	0.098

Bảng 4: Kết quả đánh giá thủ công top 10

Model	**Type**	**MRR**	**H@5**	**P@5**	**NDCG@5**	**H@10**	**P@10**	**NDCG@10**
BGE-M3	title	0.75	0.85	0.58	0.759	0.95	0.565	0.788
	overall	0.775	0.9	0.69	0.805	0.9	0.61	0.8
Doc2Vec	title	0.436	0.55	0.28	0.449	0.6	0.265	0.464
	overall	0.117	0.15	0.07	0.128	0.15	0.055	0.13
Doc2Vec-dbow	title	0.556	0.7	0.44	0.583	0.75	0.39	0.593
	overall	0.662	0.8	0.5	0.676	0.9	0.48	0.708
SemLex	title	0.86	0.95	0.68	0.886	0.95	0.6	0.868
	overall	0.861	0.95	0.68	0.87	1	0.63	0.887
LaBSE	title	0.645	0.75	0.57	0.667	0.85	0.56	0.703
	overall	0.6611	0.85	0.62	0.707	0.9	0.57	0.731
MPNET	title	0.541	0.65	0.51	0.558	0.75	0.47	0.592
	overall	0.688	0.75	0.63	0.7	0.85	0.565	0.734
TFIDF	title	0.858	0.95	0.68	0.843	1	0.625	0.85
	overall	0.727	0.8	0.62	0.731	0.9	0.57	0.769
Word2Vec	title	0.005	0	0	0	0.05	0.005	0.014
	overall	0.075	0.1	0.07	0.083	0.1	0.075	0.085
Word2Vec-sg	title	0.426	0.55	0.29	0.44	0.6	0.285	0.46
	overall	0.007	0	0	0	0.05	0.005	0.017

Bảng 2: Kết quả đánh giá top 10

Model	**Type**	H@10	P@10	NDCG@10	MAP@10	MRR@10
BGE-M3	title	1	0.62	0.67	0.05	0.917
	overall	1	0.67	0.708	0.0595	0.89
Doc2Vec	title	0.75	0.325	0.335	0.012	0.529
	overall	0.3	0.095	0.117	0.001	0.153
Doc2Vec-dbow	title	0.8	0.435	0.467	0.013	0.705
	overall	1	0.51	0.53	0.029	0.721
SemLex	title	1	0.675	0.717	0.059	0.9
	overall	1	0.75	0.771	0.072	0.912
LaBSE	title	1	0.65	0.672	0.054	0.835
	overall	1	0.725	0.733	0.057	0.827
MPNET	title	0.95	0.43	0.433	0.029	0.591
	overall	0.9	0.495	0.474	0.362	0.515
TFIDF	title	1	0.71	0.737	0.056	0.883
	overall	1	0.695	0.704	0.058	0.796
Word2Vec	title	0.25	0.05	0.045	0.00028	0.0675
	overall	0.35	0.105	0.115	0.0014	0.202
Word2Vec-sg	title	0.9	0.4	0.41	0.013	0.571
	overall	0.3	0.045	0.041	0.0007	0.091

(Exact Matching), tận dụng tốt mật độ thực thể cao trong các tiêu đề ngắn. Tuy nhiên, hiệu năng suy giảm mạnh khi mở rộng sang văn bản đầy đủ. Nguyên nhân nằm ở đặc tính biểu diễn thưa (sparse representation); độ dài văn bản tăng dẫn đến việc các từ khóa trọng tâm bị pha loãng bởi nhiễu (noise), làm giảm trọng số của các đặc trưng cốt lõi.

2. **Phân tích các mô hình Transformer:**
Kết quả thực nghiệm cho thấy sự phân hóa rõ rệt giữa MPNet, LaBSE và BGE-M3, chủ yếu do khả năng xử lý độ dài ngữ cảnh:

   - **MPNet:** Dù mạnh về tương đồng câu, mô hình gặp vấn đề "khát quát hóa ngữ nghĩa quá mức"(Semantic Over-generalization) khiến độ chính xác giảm so với phương pháp khớp từ khóa. Ngoài ra, giới hạn cửa sổ ngữ cảnh 128 tokens buộc mô hình phải cắt cụt (truncation) phần lớn nội dung quan trọng (Yêu cầu, Quyền lợi), dẫn đến chỉ số NDCG thấp hơn các mô hình xử lý văn bản dài.
   - **LaBSE vs. BGE-M3:** LaBSE bị hạn chế bởi đầu vào 256 tokens, thường chỉ bao quát được phần giới thiệu và bỏ lỡ các yêu cầu kỹ thuật chi tiết phía sau. Ngược lại, BGE-M3 với khả năng xử lý 8192 tokens và kiến trúc tối ưu cho truy xuất (Retrieval-optimized) đã khắc phục triệt để vấn đề này. BGE-M3 không chỉ nắm bắt cấu trúc cấp đoạn văn (passage-level) mà còn lọc nhiễu hiệu quả hơn LaBSE, đạt NDCG@10 lên tới 0.80 trên tập kiểm thử thủ công. Kết quả MRR cao (0.916) cũng khẳng định khả năng xếp hạng ưu việt của BGE-M3.

3. **Hiệu quả của mô hình Lai ghép (SemLex):**
Mô hình SemLex đạt hiệu suất vượt trội trên cả hai phương pháp đánh giá (NDCG@10 tự động: 0.771; thủ công: 0.886). Kết quả này chứng minh tính hiệu quả của kiến trúc lai: TF-IDF đảm bảo độ chính xác từ khóa, trong khi BGE-M3 bổ sung khả năng hiểu ngữ nghĩa sâu và xử lý văn bản dài, tạo ra sự cân bằng tối ưu giữa Precision và Recall.

4. **Tác động của chiến lược dữ liệu đầu vào:**
So sánh giữa việc chỉ sử dụng Tiêu đề (Basic) và Toàn văn (Upgrade):

   - **Nhóm thống kê (TF-IDF):** Việc bổ sung dữ liệu đầy đủ gây nhiễu, làm giảm độ chính xác.
   - **Nhóm ngữ nghĩa (SemLex, LaBSE):** Chiến lược toàn văn giúp cải thiện đáng kể độ phủ (MAP tăng từ 0.082 lên 0.105 với SemLex). Điều này xác nhận rằng ngữ cảnh chi tiết trong JD đóng vai trò quan trọng trong việc truy xuất các kết quả phù hợp về mặt ý nghĩa mà phương pháp từ khóa đơn thuần thường bỏ sót.

6.3 Kết Luận

Kết quả thực nghiệm khẳng định mô hình lai ghép SemLex (Overall) là giải pháp tối ưu nhất cho bài toán tuyển dụng, giải quyết triệt để sự đánh đổi giữa nhu cầu "Khớp từ khóa chính xác"(Lexical Matching) và "Hiểu ngữ cảnh sâu"(Semantic Understanding). Sự ưu việt được thể hiện qua ba khía cạnh:

- **Chất lượng xếp hạng vượt trội:** Với chỉ số **NDCG@10 đạt 0.887** trên tập đánh giá thủ công, hệ thống chứng minh khả năng sắp xếp các ứng viên/công việc có độ phù hợp cao lên các vị trí đầu, đảm bảo mật độ thông tin hữu ích tối đa cho người dùng.
- **Khả năng bao quát ngữ nghĩa toàn diện:** Mô hình tận dụng thành công ưu điểm kép của phương pháp thống kê TF-IDF (định danh chính xác thực thể) và kiến trúc Transformer BGE-M3 (nắm bắt cấu trúc và ngữ nghĩa đoạn văn). Kiến trúc lai này giúp hệ thống hoạt động ổn định và linh hoạt đối với cả các truy vấn từ khóa ngắn gọn lẫn các bản mô tả công việc (JD) dài và phức tạp.
- **Tối ưu hóa trải nghiệm tìm kiếm:** Chỉ số **Hit Ratio@5 đạt 0.95** trong thực nghiệm thủ công cho thấy trong đa số trường hợp, người dùng có thể tiếp cận kết quả mục tiêu ngay trong top 5 hiển thị. Điều này đồng nghĩa với việc giảm thiểu chi phí thao tác (như cuộn trang, lọc lại), gia tăng đáng kể hiệu quả tìm kiếm so với các phương pháp truyền thống.

7 Hướng phát triển

Mặc dù hệ thống khuyến nghị hiện tại (SemLex Overall) đã đạt được những kết quả khả quan về độ chính xác (NDCG@10 > 0.8), nhóm nghiên cứu nhận thấy vẫn còn nhiều dư địa để cải tiến và mở rộng trong tương lai nhằm đáp ứng tốt hơn nhu cầu thực tế của thị trường tuyển dụng. Hiện tại, hệ thống đang hoạt động chủ yếu dựa trên nội dung (Content-based Filtering) và dữ liệu tĩnh. Để nâng cao trải nghiệm cá nhân hóa, các hướng phát triển bao gồm:

- Thu thập dữ liệu hành vi: Tích hợp cơ chế ghi nhận lịch sử tương tác thực tế của người dùng (thời gian xem tin, lượt click, lượt nộp hồ sơ, lưu tin). Dữ liệu này sẽ là tiền đề để triển khai các thuật toán Collaborative Filtering Lọc cộng tác, giúp hệ thống hiểu "gu"của người dùng tốt hơn thay vì chỉ so khớp từ khóa.

- Cơ chế phản hồi chủ động: Cho phép người dùng đánh giá "Thích/Không thích"hoặc "Phù hợp/Không phù hợp"với các kết quả gợi ý. Hệ thống sẽ sử dụng dữ liệu này để cập nhật lại trọng số của mô hình SemLec theo thời gian thực.

Hiện tại, hệ thống đang sử dụng các mô hình Transformer (BGE-M3, LaBSE) ở chế độ trích xuất đặc trưng với bộ trọng số gốc (Pre-trained Inference). Để nâng cao độ chính xác trong miền dữ liệu tuyển dụng đặc thù, nhóm đề xuất lộ trình tinh chỉnh (Fine-tuning) mô hình như sau:

1. Tạo sinh dữ liệu huấn luyện bằng Generative AI (Synthetic Data Generation): Do hạn chế về dữ liệu lịch sử tương tác người dùng thực tế (User Logs), nhóm sẽ áp dụng phương pháp Augmentation sử dụng các mô hình ngôn ngữ lớn (LLMs) như GPT-4 hoặc Gemini để tự động sinh dữ liệu huấn luyện chất lượng cao:
   - Quy trình: Với mỗi bản mô tả công việc (JD) có trong cơ sở dữ liệu, sử dụng LLM đóng vai "ứng viên tiềm năng"để sinh ra các biến thể Truy vấn (Queries) hoặc Tóm tắt hồ sơ tương ứng phù hợp với JD đó.
   - Kết quả: Tạo ra hàng nghìn cặp dữ liệu mẫu (Query giả lập - JD gốc) được gán nhãn tích cực (Positive Pairs) mà không cần tốn chi phí gán nhãn thủ công.

2. Huấn luyện tinh chỉnh : Sử dụng bộ dữ liệu nhân tạo ở trên để huấn luyện lại các mô hình BGE-M3/LaBSE sử dụng hàm mất mát Contrastive Loss. Mục tiêu là giúp mô hình học được mối liên kết ngữ nghĩa sâu giữa "ngôn ngữ của ứng viên"(thường ngắn gọn, dùng từ lóng như Dev, Fresher, Comtor) và "ngôn ngữ của nhà tuyển dụng"(thường trang trọng, chi tiết). Việc này giúp khắc phục hiện tượng lệch pha ngôn ngữ mà các mô hình gốc thường gặp phải.

8 Kết luận

Đồ án "Xây dựng hệ thống khuyến nghị việc làm sử dụng mô hình lai ghép ngữ nghĩa"đã hoàn thành mục tiêu đề ra là giải quyết bài toán quá tải thông tin trên các nền tảng tuyển dụng thông qua việc áp dụng các kỹ thuật xử lý ngôn ngữ tự nhiên tiên tiến. Từ quá trình thu thập, xử lý dữ liệu thực tế trên TopCV đến việc thực nghiệm so sánh các phương pháp trích xuất đặc trưng, nhóm nghiên cứu đã chứng minh được rằng sự kết hợp giữa các mô hình thống kê truyền thống và mô hình học sâu hiện đại là chìa khóa để tối ưu hóa hiệu quả gợi ý.

Kết quả thực nghiệm cho thấy mô hình đơn lẻ thường gặp phải sự đánh đổi giữa độ chính xác từ khóa và khả năng hiểu ngữ cảnh: TF-IDF hoạt động tốt với các tiêu đề ngắn gọn nhưng kém hiệu quả với văn bản dài, trong khi các mô hình Transformer như BGE-M3 hay LaBSE cần ngữ cảnh đầy đủ để phát huy sức mạnh. Đóng góp quan trọng nhất của đồ án là việc đề xuất và kiểm chứng thành công kiến trúc lai ghép SemLec Overall, giúp dung hòa ưu điểm của cả hai phương pháp trên, đạt chỉ số NDCG@10 lên tới 0.8. Kiến trúc này không chỉ đảm bảo các công việc phù hợp nhất luôn hiển thị ở vị trí đầu mà còn giải quyết tốt vấn đề bất đồng bộ ngôn ngữ thường gặp giữa hồ sơ ứng viên và tin tuyển dụng.

Những kết quả khả quan này là tiền đề vững chắc để phát triển hệ thống thành một sản phẩm thực tế. Với

định hướng tinh chỉnh mô hình thông qua dữ liệu nhân tạo sinh bởi Generative AI trong tương lai, hệ thống hứa hẹn sẽ ngày càng hoàn thiện, mang lại trải nghiệm tìm việc cá nhân hóa và chính xác hơn cho người dùng tại thị trường Việt Nam.

References

[1] BAAI (2024). *BGE-M3: Multi-lingual, Multi-functionality, Multi-granularity Text Embeddings*. arXiv preprint arXiv:2402.03216.

[2] https://huggingface.co/BAAI/bge-m3

[3] https://huggingface.co/sentence-transformers/paraphrase-multilingual-mpnet-base-v2

[4] https://huggingface.co/sentence-transformers/LaBSE