BÁO CÁO ĐỒ ÁN
KHUYẾN NGHỊ CÔNG VIỆC

Môn học: DS300.Q11

Nhóm 10: Võ Minh Quyền 22521227
Võ Anh Quân 22521192
Võ Phi Thân 22521323
GVHD: ThS. Huỳnh Văn Tín

Mục lục

1. Giới thiệu
2. Bài toán
3. Bộ dữ liệu
4. Mô hình
5. Thực nghiệm
6. Đánh giá

Giới thiệu

Thực trạng: Hiện nay thị trường tuyển dụng trực tuyến tại Việt Nam đang phát triển bùng nổ.

Hiện nay thị trường tuyển dụng trực tuyến tại Việt Nam đang phát triển bùng nổ. Tuy nhiên, sự gia tăng đột biến về số lượng dữ liệu đã dẫn đến tình trạng "quá tải thông tin" :

- Về phía ứng viên: Việc tìm kiếm thủ công qua hàng trăm tin đăng (Job Description - JD) tốn rất nhiều thời gian và dễ bỏ sót các cơ hội phù hợp nhất.
- Về phía dữ liệu: Các bản mô tả công việc (JD) và hồ sơ năng lực (CV) trên TopCV thường có đặc thù là dữ liệu văn bản phi cấu trúc gây khó khăn cho các bộ lọc từ khóa đơn giản.

Bài toán

Nhu cầu xây dựng một hệ thống gợi ý tốt hơn, có khả năng hiểu ngữ nghĩa văn bản để tự động khớp nối các thông tin ứng viên và JD là vô cùng cần thiết.

→ Vậy nên nhóm đã tiến hành đề tài khuyến nghị công việc giúp ứng viên có thể dễ dàng tìm kiếm được công việc phù hợp với độ chính xác cao hơn.

Bộ dữ liệu

Data được thu thập từ TopCV bằng cách sử dụng Airflow để tiền xử lý ban đầu và thu được dữ liệu

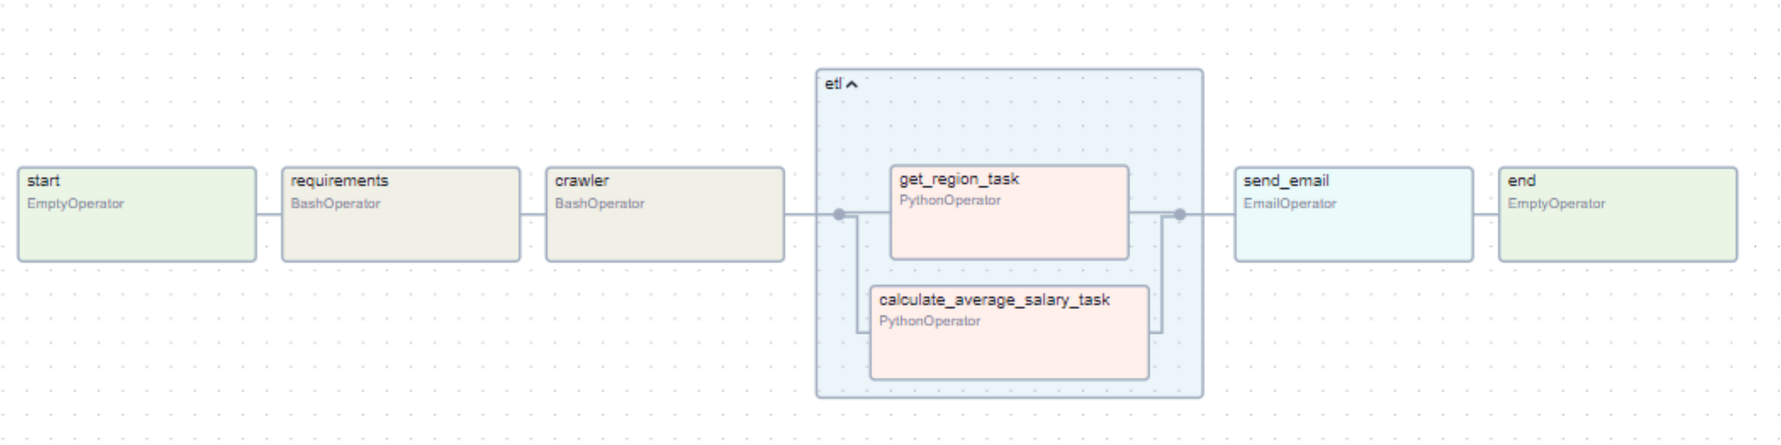

Bộ dữ liệu

Data được thu thập từ TopCV bằng cách sử dụng airflow

id	job_url	title	salary_range	min_salary	max_salary	avg_salary	location	region
1	https://www.topcv.vn/viec-lam/ke-toan-tong-hop-di-...	Tuyển Kế Toán Tổng Hợp - Đi Làm Ngay làm việc tại ...	11 - 14 triệu	11.00	14.00	12.50	Hồ Chí Minh	Miền Nam
2	https://www.topcv.vn/viec-lam/nhan-vien-seo-websit...	Tuyển Nhân Viên Seo Website Đi Làm Ngay - Thu Nhập...	10 - 20 triệu	10.00	20.00	15.00	Hà Nội	Miền Bắc
3	https://www.topcv.vn/viec-lam/ky-su-giam-sat-thi-c...	Tuyển Kỹ Sư Giám Sát Thi Công Lắp Đặt Công Nghệ Xử...	12 - 20 triệu	12.00	20.00	16.00	Hồ Chí Minh	Miền Nam
4	https://www.topcv.vn/viec-lam/chuyen-vien-phat-tri...	Tuyển Chuyên Viên Phát Triển Kinh Doanh - Lương Cơ...	10 - 15 triệu	10.00	15.00	12.50	Miền Bắc, Hà Nội	Miền Bắc

Bộ dữ liệu

Bộ dữ liệu được thu thập từ trang web TopCV với 6473 công việc.
Bộ dữ liệu gồm 15 cột dữ liệu.

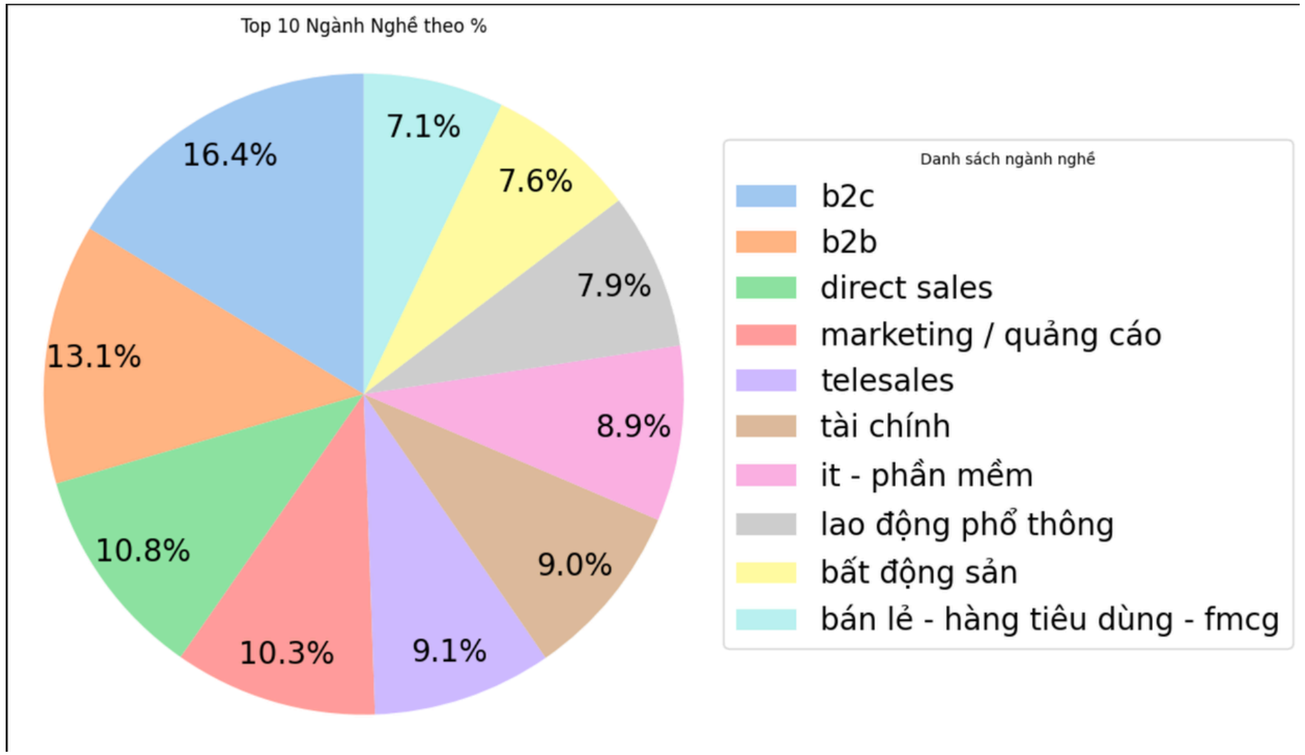

Bộ dữ liệu

Bộ dữ liệu được thu thập từ trang web TopCV với 6473 công việc.
Bộ dữ liệu gồm 15 cột dữ liệu.

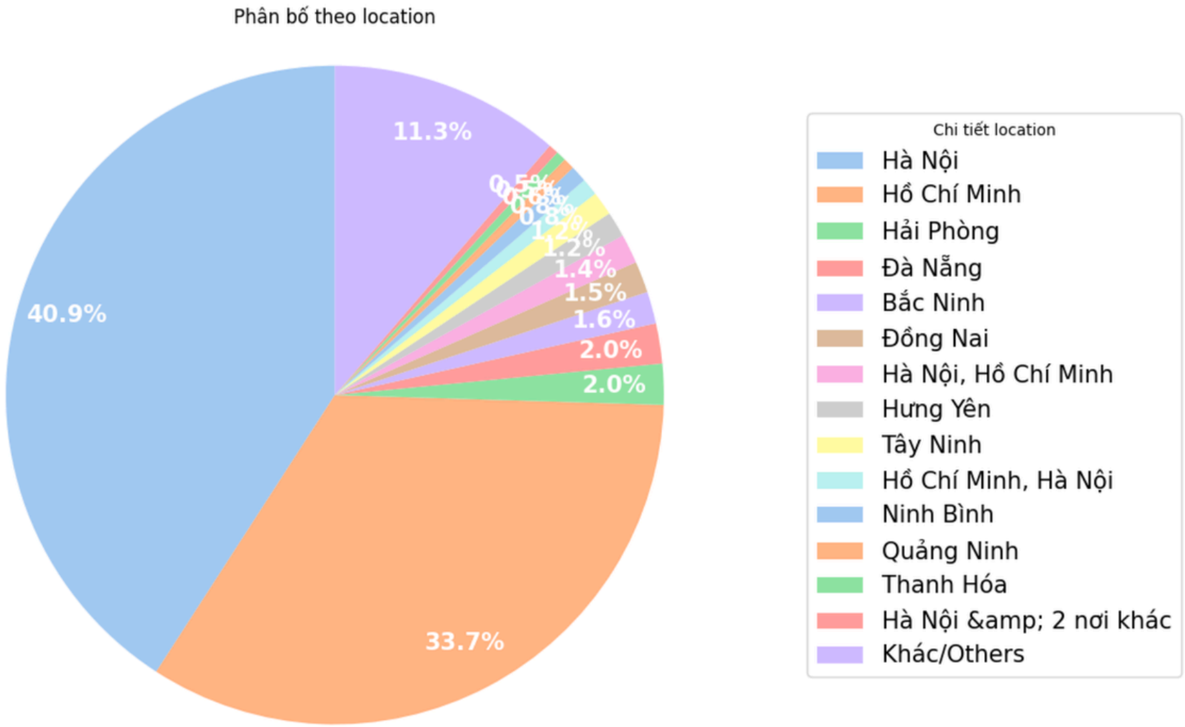

Bộ dữ liệu

Tuy nhiên, sau quá trình tiền xử lý dữ liệu, bộ dữ liệu chỉ còn lại những cột dữ liệu sau:

- title: Tiêu đề công việc
- description: Mô tả công việc
- requirements: Yêu cầu công việc
- benefit: Quyền lợi
- type: Loại công việc
- location: Địa chỉ công ty
- position: Vị trí công việc
- salary_range: Mức lương

Bộ dữ liệu

Tuy nhiên, sau quá trình tiền xử lý dữ liệu, bộ dữ liệu chỉ còn lại những cột dữ liệu sau:

- specializations: Năng lực cơ bản
- min_salary_edited: Mức lương thấp nhất đã được chỉnh sửa
- max_salary_edited: Mức lương cao nhất đã được chỉnh sửa
- currency_salary: Đơn giá lương
- overall_text: Cột dữ liệu hợp từ các cột title, description, requirements và benefit
- title_processed: Cột title đã được xử lý và loại bỏ stopword
- overall_text_processed: Cột overall đã được xử lý và loại bỏ stopword

Mô hình

Các mô hình khuyến nghị content-based được ứng dụng vào đề tài:

- TF-IDF
- Các mô hình embedding đa ngôn ngữ: BGE-M3, paraphrase-multilingual-mpnet-base-v2, LaBSE
- Word2Vec: CBOW (Continuos Bag of Words) và Skip-gram
- Doc2Vec: PV-DM (Distributed Memory) và PV-DBOW (Distributed Bag of Words)

Mô hình

Ngoài ra, nhóm còn áp dụng các phương pháp lai vào đề tại nhằm cho ra khuyến nghị tốt nhất.

- Weighted: kết hợp giữa TF-IDF và BGE-M3 với tỉ lệ 3:7
- Switching: chuyển đổi mô hình cũng như cột dữ liệu tham chiếu theo yêu cầu của người dùng.

Thực nghiệm

Hai chiến lược đánh giá:

- **Title-based(Query <-> Job Title):** Đánh giá khả năng khớp lệnh nhanh, chính xác theo tên vị trí.
- **Overall-based(Query <-> Full Content):** Đánh giá khả năng hiểu sâu ngữ nghĩa, tìm job phù hợp nội dung dù tiêu đề khác biệt.

Xây dựng chuẩn đánh giá

Thách thức: Dữ liệu TopCV không có lịch sử tương tác.

Quy trình:

- **Bước 1:** Chuẩn bị tập 20 Queries đại diện cho các ngành nghề trên TopCV, trích xuất 3 từ khoá cốt lõi. Ví dụ: "Nhân viên xuất nhập khẩu Logistics tiếng Trung" → {"xuất nhập khẩu", "logistics", "tiếng trung"}
- **Bước 2:** So khớp từ khóa và Nội dung Job, chọn ngưỡng là 2 (Khớp ít nhất 2/3 từ khóa)
  - Ngưỡng 3/3: Quá khắt khe có thể bỏ sót job tốt (False Negative).
  - Ngưỡng 1/3: Quá lỏng lẻo, nhiều job rác (False Positive).

$$\mathrm{Label}(q, d) = \begin{cases} 1, & \text{nếu } |K_q \cap d| \geq \theta, \\ 0, & \text{nếu } |K_q \cap d| < \theta. \end{cases}$$

Các thang đo đánh giá

Để đánh giá khả năng “lọc nhiễu“ và “tìm thấy“ của hệ thống:

- **Precision@K**: Tỷ lệ kết quả phù hợp trong Top K, đảm bảo ứng viên không bị “ngợp“ bởi tin rác.
- **Hit Ratio@K**: Tỷ lệ truy vấn tìm được ít nhất 1 kết quả đúng, đảm bảo hệ thống không trả về danh sách rỗng hoặc toàn sai.

Đánh giá chất lượng xếp hạng:

- **MRR**: Đo lường thứ hạng của kết quả đúng đầu tiên, tối ưu cho nhu cầu tìm kiếm nhanh (thấy là click ngay).
- **MAP**: Đánh giá độ phủ và thứ hạng của toàn bộ kết quả đúng, đảm bảo các job phù hợp được “gom cụm“ lên trên, không nằm rải rác.
- **NDCG:** Đánh giá xếp hạng có trọng số giảm dần, phạt nặng hệ thống nếu để các job phù hợp nhất trôi xuống dưới đáy.

Đánh giá

Kết quả đánh giá theo chuẩn đã được xây dựng

Model	Type	H@5	P@5	NDCG@5	MAP@5	MRR@5	H@10	P@10	NDCG@10	MAP@10	MRR@10	H@20	P@20	NDCG@20	MAP@20	MRR@20
BGE-M3	title	1	0.72	0.75	0.032	0.917	1	0.62	0.67	0.05	0.917	1	0.545	0.6	0.072	0.917
	overall	0.95	0.73	0.76	0.037	0.885	1	0.67	0.708	0.0595	0.89	1	0.62	0.66	0.087	0.89
Doc2Vec	title	0.75	0.36	0.36	0.009	0.529	0.75	0.325	0.335	0.012	0.529	0.9	0.285	0.3	0.016	0.541
	overall	0.2	0.08	0.087	0.0008	0.142	0.3	0.095	0.117	0.001	0.153	0.3	0.1125	0.107	0.0024	0.153
Doc2Vec-dbow	title	0.75	0.48	0.51	0.01	0.7	0.8	0.435	0.467	0.013	0.705	0.85	0.42	0.445	0.022	0.709
	overall	0.95	0.55	0.563	0.021	0.717	1	0.51	0.53	0.029	0.721	1	0.497	0.515	0.042	0.722
SemLex	title	1	0.79	0.8	0.037	0.9	1	0.675	0.717	0.059	0.9	1	0.6	0.652	0.082	0.9
	overall	0.9	0.74	0.781	0.04	0.9	1	0.75	0.771	0.072	0.912	1	0.672	0.712	0.105	0.912
LaBSE	title	1	0.68	0.7	0.035	0.835	1	0.65	0.672	0.054	0.835	1	0.57	0.605	0.079	0.835
	overall	1	0.77	0.763	0.032	0.827	1	0.725	0.733	0.057	0.827	1	0.666	0.872	0.084	0.827
MPNET	title	0.8	0.42	0.427	0.017	0.572	0.95	0.43	0.433	0.029	0.591	1	0.43	0.433	0.048	0.594
	overall	0.8	0.47	0.447	0.02	0.5	0.9	0.495	0.474	0.362	0.515	1	0.467	0.464	0.057	0.522
TFIDF	title	1	0.78	0.787	0.034	0.883	1	0.71	0.737	0.056	0.883	1	0.602	0.654	0.075	0.883
	overall	0.9	0.2	0.722	0.034	0.78	1	0.695	0.704	0.058	0.796	1	0.685	0.697	0.094	0.796
Word2Vec	title	0.1	0.05	0.042	0.0002	0.05	0.25	0.05	0.045	0.00028	0.0675	0.3	0.055	0.05	0.00049	0.07
	overall	0.3	0.13	0.132	0.001	0.195	0.35	0.105	0.115	0.0014	0.202	0.35	0.095	0.104	0.0024	0.202
Word2Vec-sg	title	0.75	0.41	0.418	0.008	0.551	0.9	0.4	0.41	0.013	0.571	0.95	0.385	0.394	0.019	0.576
	overall	0.15	0.03	0.031	0.004	0.0725	0.3	0.045	0.041	0.0007	0.091	0.4	0.05	0.046	0.0001	0.098

Đánh giá

- Với nhóm thống kê (TF-IDF, Doc2Vec,...): Việc thêm dữ liệu làm giảm độ chính xác do nhiễu.
- Transformer có chỉ số MRR cực cao, hiệu năng tăng khi có thêm mô tả.
- SemLex có kết quả đánh giá thống trị trên cả 2 phương pháp nhờ giữ Top các kết quả khớp từ khóa chính xác và vớt được các kết quả phù hợp ngữ nghĩa (nhờ BGE).

Kết quả đánh giá thủ công

Model	Type	MRR	H@5	P@5	NDCG@5	H@10	P@10	NDCG@10
BGE-M3	title	0.75	0.85	0.58	0.759	0.95	0.565	0.788
	overall	0.775	0.9	0.69	0.805	0.9	0.61	0.8
Doc2Vec	title	0.436	0.55	0.28	0.449	0.6	0.265	0.464
	overall	0.117	0.15	0.07	0.128	0.15	0.055	0.13
Doc2Vec-dbow	title	0.556	0.7	0.44	0.583	0.75	0.39	0.593
	overall	0.662	0.8	0.5	0.676	0.9	0.48	0.708
SemLex	title	0.86	0.95	0.68	0.886	0.95	0.6	0.868
	overall	0.861	0.95	0.68	0.87	1	0.63	0.887
LaBSE	title	0.645	0.75	0.57	0.667	0.85	0.56	0.703
	overall	0.6611	0.85	0.62	0.707	0.9	0.57	0.731
MPNET	title	0.541	0.65	0.51	0.558	0.75	0.47	0.592
	overall	0.688	0.75	0.63	0.7	0.85	0.565	0.734
TFIDF	title	0.858	0.95	0.68	0.843	1	0.625	0.85
	overall	0.727	0.8	0.62	0.731	0.9	0.57	0.769
Word2Vec	title	0.005	0	0	0	0.05	0.005	0.014
	overall	0.075	0.1	0.07	0.083	0.1	0.075	0.085
Word2Vec-sg	title	0.426	0.55	0.29	0.44	0.6	0.285	0.46
	overall	0.007	0	0	0	0.05	0.005	0.017

Hướng phát triển

- Cải thiện mô hình bằng nhiều mô hình RS tốt hơn cho tiếng việt
- Thêm chức năng gợi ý công việc dựa trên CV
- Xử lý dữ liệu tiếng anh trong bộ dữ liệu tốt hơn
- Thêm trọng số vào các từ quan trọng cũng như đánh được trọng số theo thời gian
- Sử dụng LLM tạo bộ dữ liệu huấn luyện chất lượng cao để vận dụng sức mạnh của các mô hình Transformer

DEMO